Atelier : Surveillance statistique d'une machine industrielle

Simulation – Estimation – EQM – LGN – TCL – Intervalles de confiance – Chaînes de Markov

Objectif

Une entreprise souhaite surveiller une machine industrielle afin d'estimer sa fiabilité, de quantifier l'incertitude de ses estimations et de prévoir son comportement à long terme.
On commencera par modéliser la durée de fonctionnement avant une panne. On utilisera ensuite des simulations pour estimer des quantités inconnues, étudier les erreurs d'estimation et illustrer la loi des grands nombres ainsi que le théorème central limite.
Enfin, on adoptera un second modèle dans lequel l'état de la machine évolue au cours du temps selon une chaîne de Markov. On étudiera alors les fréquences de visite, la distribution stationnaire et la disponibilité à long terme de la machine.

Les questions auxquelles on souhaite répondre sont les suivantes :

— Quelle est la durée moyenne de fonctionnement avant une panne ?

— Comment estimer une probabilité de panne à partir de données ?

— Comment mesurer l'erreur d'un estimateur ?

— Comment évolue la précision lorsque la taille de l'échantillon augmente ?

— Comment quantifier l'incertitude d'une estimation ?

— Comment décrire l'évolution de l'état de la machine ?

— Quelle proportion de temps la machine passe-t-elle dans chacun de ses états ?

— Comment estimer sa disponibilité et son coût moyen à long terme ?

1 Partie I – Simulation d'une durée avant panne

1.1 Modélisation

On note T la durée, en heures, entre deux pannes successives.

Dans un premier modèle simplifié, on suppose que T suit une loi exponentielle de paramètre $\lambda > 0$: $T \sim \mathcal{E}(\lambda)$.

Sa densité est donnée par

$$f_T(t) = \lambda e^{-\lambda t}, \qquad t \geq 0.$$

Sa fonction de répartition est donnée par

$$F_X(x) = \begin{cases} 0 & \text{si } x < 0, \\ 1 - e^{-\lambda x} & \text{si } x \geq 0. \end{cases}$$

On choisit $\lambda = 0.1$.

On rappelle que

$$\mathbb{E}(T) = \frac{1}{\lambda} = 10 \quad \text{et} \quad \mathrm{Var}(T) = \frac{1}{\lambda^2} = 100.$$

Question 1 – Simulation et visualisation

À l'aide de Python, simuler $N = 1000$ durées de fonctionnement indépendantes suivant cette loi.

a) Afficher les dix premières valeurs simulées.

b) Calculer la moyenne, le minimum et le maximum de l'échantillon.

c) Tracer l'histogramme des durées simulées et superposer la densité théorique.

d) Commenter le graphique. Pourquoi l'histogramme ne coïncide-t-il pas exactement avec la densité théorique ?

Question 2 – Estimation d'une probabilité

On souhaite estimer la probabilité qu'une panne survienne dans les cinq premières heures :

$$p = \mathbb{P}(T \leq 5).$$

a) Calculer théoriquement p.

b) Construire un estimateur de p à partir de l'échantillon simulé.

c) Comparer l'estimation obtenue avec la valeur théorique.

2 Partie II – Estimation et erreur quadratique moyenne

2.1 Estimation du paramètre

On suppose maintenant que le paramètre λ est inconnu.
On dispose d'un échantillon de durées indépendantes et de même loi : $T_1, \ldots, T_n$.
La moyenne empirique est

$$\overline{T}_n = \frac{1}{n} \sum_{i=1}^{n} T_i.$$

Puisque $\mathbb{E}(T) = \frac{1}{\lambda}$,, on peut estimer λ par

$$\widehat{\lambda}_n = \frac{1}{\overline{T}_n}.$$

Question 3 – Estimation de λ

À partir des données simulées dans la partie I :

a) calculer $\overline{T}_{1000}$;

b) calculer $\widehat{\lambda}_{1000}$;

c) comparer cette estimation à la valeur théorique $\lambda = 0.1$.

Répéter le calcul pour des tailles d'échantillon

$$n \in \{10, 50, 100, 500, 1000, 10000\}.$$

Présenter les résultats dans un tableau.

2.2 Erreur quadratique moyenne

On souhaite maintenant estimer la durée moyenne de fonctionnement : $\mu = \mathbb{E}(T) = 10$.

On considère les deux estimateurs suivants :

$$\widehat{\mu}_{1,n} = \overline{T}_n, \qquad \widehat{\mu}_{2,n} = \frac{n}{n+1}\overline{T}_n.$$

Pour un estimateur $\widehat{\mu}_n$ de μ, on définit l'erreur quadratique moyenne par

$$\boxed{\mathrm{EQM}(\widehat{\mu}_n) = \mathrm{Var}(\widehat{\mu}_n) + \left(\mathbb{E}(\widehat{\mu}_n) - \mu\right)^2.}$$

Le second terme est le carré du biais de l'estimateur.

Question 4 – Comparaison des estimateurs

On considère les deux estimateurs de $\mu = 10$:

$$\widehat{\mu}_{1,n} = \overline{T}_n \qquad \text{et} \qquad \widehat{\mu}_{2,n} = \frac{n}{n+1}\overline{T}_n,$$

où $\overline{T}_n$ désigne la moyenne d'un échantillon de taille n.

À l'aide de Python, on réalisera $M = 10\,000$ simulations indépendantes pour chaque taille d'échantillon $n = 10$, $n = 50$ et $n = 100$.

a) Pour chaque simulation, calculer les deux estimateurs $\widehat{\mu}_{1,n}$ et $\widehat{\mu}_{2,n}$.

b) Estimer le biais de chaque estimateur à l'aide de la moyenne des valeurs obtenues :

$$\widehat{B} = \frac{1}{M}\sum_{k=1}^{M} \widehat{\mu}^{(k)} - \mu.$$

c) Estimer l'EQM de chaque estimateur :

$$\widehat{\mathrm{EQM}} = \frac{1}{M}\sum_{k=1}^{M} \left(\widehat{\mu}^{(k)} - \mu\right)^2.$$

d) Comparer les EQM estimées aux valeurs théoriques

$$\mathrm{EQM}(\widehat{\mu}_{1,n}) = \frac{100}{n}, \qquad \mathrm{EQM}(\widehat{\mu}_{2,n}) = \frac{100}{n+1}.$$

e) Pour chaque taille d'échantillon, afficher les EQM estimées et les EQM théoriques dans un tableau. Conclure sur les performances des deux estimateurs.

3 Partie III – Loi des grands nombres

La loi des grands nombres permet de formaliser la stabilisation des moyennes empiriques lorsque la taille de l'échantillon augmente.

Question 5 – Convergence de la moyenne empirique

À partir des durées simulées dans la partie I, calculer les moyennes cumulées

$$\overline{T}_n = \frac{1}{n}\sum_{i=1}^{n} T_i, \qquad n = 1, \dots, N.$$

Tracer la courbe $n \mapsto \overline{T}_n$ et ajouter la droite horizontale

$$y = \mathbb{E}(T) = 10.$$

Décrire le comportement de la courbe lorsque n augmente.

Question 6 – Convergence des estimateurs

On considère l'estimateur de probabilité

$$\widehat{p}_n = \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}_{\{T_i \leq 5\}}.$$

a) Expliquer pourquoi les variables

$$Y_i = \mathbf{1}_{\{T_i \leq 5\}}$$

sont indépendantes, de même loi et intégrables.

b) Déterminer $\mathbb{E}(Y_i)$.

c) En déduire la convergence de $\widehat{p}_n$ vers p.

4 Partie IV – TCL et intervalles de confiance

La loi des grands nombres décrit la convergence d'un estimateur. Elle ne quantifie cependant pas directement ses fluctuations.

Le théorème central limite permet d'étudier ces fluctuations et de construire des intervalles de confiance approximatifs.

4.1 Fluctuations de la fréquence empirique

On rappelle que

$$p = \mathbb{P}(T \leq 5) \quad \text{et} \quad \widehat{p}_n = \frac{1}{n}\sum_{i=1}^{n} Y_i, \qquad Y_i = \mathbf{1}_{\{T_i \leq 5\}}.$$

Les variables Y_i suivent une loi de Bernoulli de paramètre p. Ainsi,

$$\mathbb{E}(Y_i) = p, \qquad \mathrm{Var}(Y_i) = p(1-p).$$

Question 7 – TCL

a) À l'aide de Python, simuler $M = 10\,000$ échantillons de taille $n = 100$, puis calculer pour chaque échantillon la fréquence empirique $\widehat{p}_n$ des pannes survenant avant 5 heures.

b) Tracer l'histogramme des fréquences empiriques obtenues, en choisissant l'option `density=True`.

c) Sur le même graphique, superposer la densité de la loi normale

$$\mathcal{N}\left(p, \frac{p(1-p)}{n}\right).$$

On pourra utiliser la fonction `norm.pdf` du module `scipy.stats` pour calculer la densité de la loi normale.

4.2 Intervalle de confiance à 95 %

Pour un échantillon suffisamment grand, on utilise l'approximation

$$\widehat{p}_n \approx \mathcal{N}\left(p, \frac{p(1-p)}{n}\right).$$

Comme p est inconnu, on le remplace par $\widehat{p}_n$ dans l'estimation de l'écart-type. On obtient l'intervalle de Wald :

$$\boxed{IC_{95\%} = \left[\widehat{p}_n - 1.96\sqrt{\frac{\widehat{p}_n(1-\widehat{p}_n)}{n}},\ \widehat{p}_n + 1.96\sqrt{\frac{\widehat{p}_n(1-\widehat{p}_n)}{n}}\right].}$$

Question 8 – Application numérique

Sur un échantillon de taille $n = 100$, on observe

$$\widehat{p}_{100} = 0.32.$$

a) Calculer l'intervalle de confiance à 95 %.

b) Interpréter le résultat.

Question 9 – Couverture par simulation

On souhaite illustrer expérimentalement l'interprétation fréquentiste d'un intervalle de confiance. On connaît ici la vraie valeur

$$p = 1 - e^{-0.5}.$$

a) Réaliser $M = 1000$ simulations indépendantes de $n = 100$ durées exponentielles.

b) Pour chaque échantillon, calculer $\widehat{p}_n$ et construire l'intervalle de confiance à 95 %.

c) Compter le nombre d'intervalles contenant la vraie valeur p.

d) Calculer la proportion d'intervalles qui contiennent p. Comparer le résultat à 95 %.

5 Partie V – Modélisation par une chaîne de Markov

5.1 Changement de modèle

Jusqu'à présent, nous avons étudié la durée de fonctionnement avant une panne à l'aide d'une loi exponentielle.

Ce modèle permet d'estimer une durée moyenne et une probabilité de panne, mais il ne distingue pas les différents états de fonctionnement de la machine.

Nous allons maintenant adopter un second modèle. À chaque heure, la machine peut fonctionner normalement, fonctionner en mode dégradé ou être en panne. Son évolution sera décrite par une chaîne de Markov.

5.2 États et matrice de transition

On considère l'espace d'états $E = \{N, D, P\}$, où :

— N : fonctionnement normal ;

— D : fonctionnement dégradé ;

— P : machine en panne.

On suppose que l'état futur dépend uniquement de l'état actuel. La matrice de transition est

$$P = \begin{pmatrix} 0.85 & 0.14 & 0.01 \\ 0.20 & 0.65 & 0.15 \\ 0.50 & 0.00 & 0.50 \end{pmatrix}.$$

L'ordre des états est (N, D, P).

Par exemple, $P_{12} = 0.14$ signifie que la probabilité de passer de l'état normal à l'état dégradé en une heure est égale à 0.14.

Question 10 – Vérification de la matrice

Vérifier que P est une matrice de transition.

5.3 Simulation d'une trajectoire

On choisit comme état initial $X_0 = N$.

À chaque étape, l'état suivant est tiré selon la ligne de la matrice correspondant à l'état actuel.

Pour le calcul informatique, on pourra utiliser la représentation $N = 0, \qquad D = 1, \qquad P = 2.$

Question 11 – Simulation et fréquences de visite

a) Simuler une trajectoire
$$X_0, X_1, \ldots, X_{999}.$$

b) Afficher les vingt premiers états obtenus.

c) Calculer les fréquences de visite
$$f_N(i) = \frac{1}{N} \sum_{k=0}^{N-1} \mathbf{1}_{\{X_k = i\}}, \qquad i \in E.$$

d) Vérifier que la somme des trois fréquences est égale à 1.

Présenter les résultats dans un tableau.

5.4 Distribution à un instant donné

On note

$$\mu_n = \big(\mathbb{P}(X_n = N), \mathbb{P}(X_n = D), \mathbb{P}(X_n = P)\big).$$

La distribution de l'état à l'instant n vérifie

$$\boxed{\mu_{n+1} = \mu_n P}$$

et donc

$$\boxed{\mu_n = \mu_0 P^n}.$$

Question 12 – Évolution de la distribution

On suppose que la machine est initialement normale :

$$\mu_0 = (1, 0, 0).$$

a) Calculer μ_1, μ_2 et μ_3.

b) Interpréter les composantes de μ_3.

c) Calculer numériquement μ_n pour plusieurs valeurs de n et observer son comportement.

5.5 Distribution stationnaire

On cherche une distribution π qui reste inchangée après une étape :

$$\boxed{\pi P = \pi}.$$

Elle vérifie également

$$\pi_N + \pi_D + \pi_P = 1 \quad \text{et} \quad \pi_N, \pi_D, \pi_P \geq 0.$$

Question 13 – Calcul et interprétation

a) Déterminer π en résolvant le système

$$\pi P = \pi, \qquad \pi_N + \pi_D + \pi_P = 1.$$

Indication : utiliser la fonction `solve`

b) Interpréter les trois composantes de π.

c) Comparer les composantes de π aux fréquences de visite obtenues sur des trajectoires de longueur 1000 puis 10000.

d) Comparer également μ_n à π lorsque n augmente.

5.6 Disponibilité et coût moyen à long terme

On considère que la machine est indisponible lorsqu'elle est en panne, c'est-à-dire dans l'état P.
La disponibilité à long terme est alors

$$\boxed{A = 1 - \pi_P}.$$

La proportion de temps passée en fonctionnement normal est, quant à elle,

$$\boxed{A_N = \pi_N}.$$

Ces deux quantités sont différentes, puisque l'état dégradé est ici considéré comme disponible.

On associe également à chaque état un coût horaire :

$$g(N) = 0, \qquad g(D) = 100, \qquad g(P) = 1000.$$

Pour une trajectoire, le coût moyen observé est

$$C_N = \frac{1}{N} \sum_{k=0}^{N-1} g(X_k).$$

Question 14 – Disponibilité et coût moyen

a) Calculer la disponibilité à long terme A et la proportion de temps passée en fonctionnement normal.

b) Calculer le coût moyen observé C_N à partir de la trajectoire simulée.

c) Montrer que
$$C_N = f_N(N)g(N) + f_N(D)g(D) + f_N(P)g(P).$$

d) En déduire la valeur théorique du coût moyen à long terme :

$$\boxed{C_\infty = \pi_N g(N) + \pi_D g(D) + \pi_P g(P).}$$

e) Comparer le coût empirique et le coût théorique. Expliquer l'intérêt de ce calcul pour l'entreprise.